Formation 5 :

Encoder une base de données : que faire des String

Plan :

Rappels

Comment encoder les Chaines de Caractères

Data Leakage

Rappels

- df = pd.read_csv(« »)

- df.info()

➔ Drop les colonnes / lignes avec trop de Nan

➔

```
from sklearn.impute import SimpleImputer
my_imputer = SimpleImputer(strategy='mean')
df['column name'] = my_imputer.fit_transform(df[['column name']])
```

Encoder les chaines de caractères

Encoder des chaines de caractères

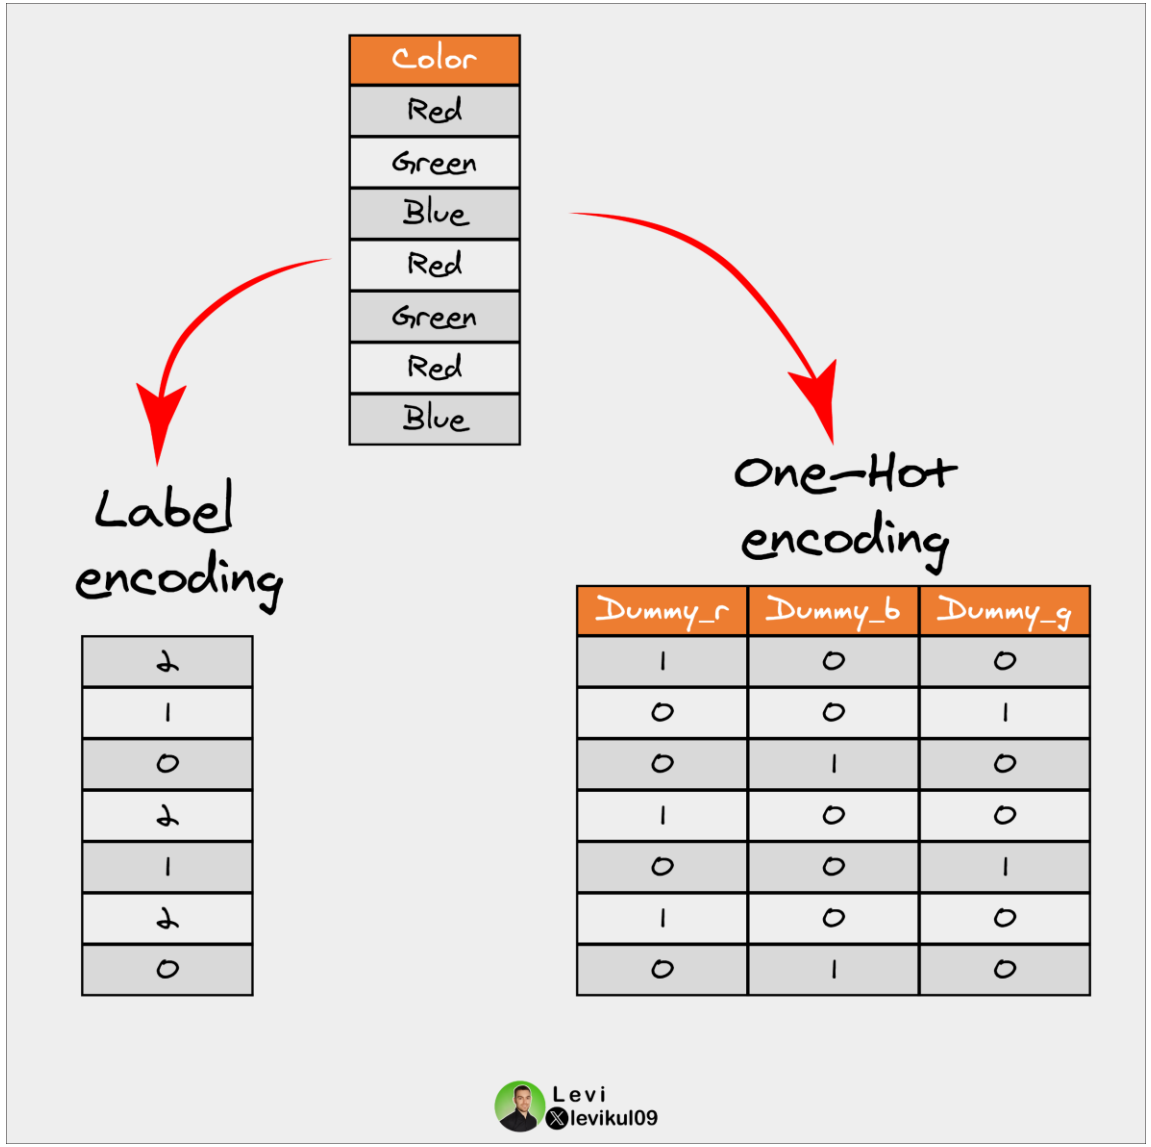

```
dataset['Neighborhood']
```

[11] ✓ 0.0s

```
0       CollgCr
1       Veenker
2       CollgCr
3       Crawfor
4       NoRidge
         ...
1455    Gilbert
1456     NWAmes
1457    Crawfor
1458      NAmes
1459    Edwards
Name: Neighborhood, Length: 1460, dtype: object
```

```
import sklearn
```

[7] ✓ 0.8s

```
from sklearn.preprocessing import OrdinalEncoder
oridnal_encoder = OrdinalEncoder()
dataset['Neighborhood']= oridnal_encoder.fit_transform(dataset[['Neighborhood']])
```

[14] ✓ 0.0s

```
dataset['Neighborhood']
```

[15] ✓ 0.0s

```
0        5.0
1       24.0
2        5.0
3        6.0
4       15.0
        ...
1455     8.0
1456    14.0
1457     6.0
1458    12.0
```

Label Encoding

```python
from sklearn.preprocessing import OneHotEncoder
OH_encoder = OneHotEncoder(sparse_output = False)
encoded_features = OH_encoder.fit_transform(dataset[['Neighborhood']])
encoded_df = pd.DataFrame(encoded_features, columns=OH_encoder.get_feature_names_out(['Neighborhood']))
df = pd.concat([dataset, encoded_df], axis=1).drop(columns=['Neighborhood'])
```

[45] ✓ 0.0s

```python
encoded_df['Neighborhood_CollgCr']
```

[46] ✓ 0.0s

```
0       1.0
1       0.0
2       1.0
3       0.0
4       0.0
       ...
1455    0.0
1456    0.0
1457    0.0
1458    0.0
1459    0.0
Name: Neighborhood_CollgCr, Length: 1460, dtype: float64
```

One Hot Encoding

Data Leakage

Qu’est ce que c’est ?

- Ca désigne une situation ou des informations auxquelles on n’est pas censé avoir accès se retrouvent dans notre jeu de training
- Résultat similaire à de l’overfitting mais en plus vicieux : performances excellentes sur le jeu de test mais très mauvaises sur des exemples réels
- Se distingue en 2 types : target leakage et train-test contamination

Data Leakage

got_pneumonia	age	weight	male	took_antibiotic_medicine	...
False	65	100	False	False	...
False	72	130	True	False	...
True	58	100	False	True	...

Train-Test Contamination

- Le fit doit toujours se faire sur X_train et jamais sur la dataset entière
- On n'applique que le transform sur X_test

```
from sklearn.impute import SimpleImputer
from sklearn.model_selection import train_test_split
import pandas as pd

df = pd.read_csv('data.csv')
imputer = SimpleImputer(strategy='mean')
df_imputed = pd.DataFrame(imputer.fit_transform(df), columns=df.columns)
X_train, X_test, y_train, y_test = train_test_split(df_imputed.drop('target', axis=1), df_imputed['target'], test_size=0.2, random_state=42)
```

Version corrigée

```python
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.impute import SimpleImputer

# Chargement
df = pd.read_csv("data.csv")
X = df.drop(columns="target")
y = df["target"]  # généralement une Series, on n'impute pas y ici

# Split avant tout fitting
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=None  # ou stratify=y si classification
)

# Imputer seulement sur X
imputer = SimpleImputer(strategy="mean")
X_train_imp = imputer.fit_transform(X_train)   # fit sur le train uniquement
X_test_imp  = imputer.transform(X_test)
```

A vous de jouer !

TP : Houses Price – Partie 2

- Encoder la BDD puis entrainer dessus un modèle XGboost

- Premières étapes :

1. Aller sur https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques

2. df = pd.read_csv("/kaggle/input/house-prices-advanced-regression-techniques/train.csv")

Ce que vous devez faire

- Encoder toutes les colonnes chaines de caractère
- Encoder la dataset de sorte qu’il n’y ait plus de Nan (cf forma 4)

- Optionnel : entrainer dessus un modèle XGBoost et vérifier ses performances